

Rapport d'utilisation des données DHS

Projet : Déterminants socio-démographiques de la malnutrition infantile en République du Congo

Auteur : MPOY Schekina Lutte-De-Vie

Institution : Université Denis Sassou Nguesso (UDSN), Kintélé

Email : mpoyschekinaluttedevie@gmail.com

Date de début : 19 juin 2026

Statut : Finalisé — soumis au DHS Program

1. Description des données utilisées

1.1 Source

Les données utilisées dans ce projet sont issues du Programme des Enquêtes Démographiques et de Santé (DHS Program), financé par l'USAID. L'accès aux microdonnées a été obtenu dans le cadre d'une demande académique approuvée le 22 juin 2026.

1.2 Fichiers utilisés

Pays	Enquête	Fichier	Lignes	Colonnes
Congo (Brazzaville)	Standard DHS 2011-12	CGKR61FL.DTA (Children's Recode)	9 329	1 110
Congo (Brazzaville)	Standard DHS 2011-12	CGHR61FL.DTA (Household Recode)	11 632	3 194

Les fichiers RDC 2023-24 et Cameroun 2018 ont également été obtenus mais n'ont pas été exploités dans cette première itération du projet (voir section 4.2, perspectives d'extension).

1.3 Préparation des données

Après chargement des fichiers bruts, les étapes suivantes ont été appliquées :

1. **Sélection des variables pertinentes :** 8 variables retenues dans KR (Z-scores anthropométriques, identifiants démographiques, clés de jointure) et 8 dans HR (caractéristiques socio-économiques du ménage).
2. **Traitement des codes aberrants DHS :** 146 valeurs ≥ 9000 sur la variable hw70 (codes 9996, 9998, 9999 signalant des mesures manquantes ou hors limites) ont été remplacées par NaN avant la conversion en Z-scores réels (division par 100).
3. **Exclusion des observations sans mesures anthropométriques :** 4 854 lignes sans Z-score taille/âge (hw70) ont été exclues, correspondant à des enfants non présents lors de la mesure. Le dataset effectif est de **4 475 enfants mesurés**.
4. **Fusion KR + HR :** Les deux fichiers ont été joints sur la clé composite cluster/ménage. La fusion est complète, aucun enfant sans correspondance ménage, 0 valeur manquante introduite.
5. **Construction de la variable cible :** La variable binaire **stunting** a été créée selon le seuil OMS standard (Z-score taille/âge < -2.0).

1.4 Distribution de la variable cible

Statut	Effectif	Proportion
Stunting (retard de croissance)	1 197	26.7%
Normal	3 278	73.3%
Total	4 475	100%

Un déséquilibre modéré est observé (26.7% de cas positifs). La stratégie retenue pour la modélisation est l'utilisation de `class_weight='balanced'` dans les modèles scikit-learn.

2. Résultats de l'analyse exploratoire

2.1 Facteurs socio-démographiques associés au stunting

L'analyse exploratoire a examiné sept facteurs socio-démographiques disponibles dans les données DHS Congo 2011-12, en comparant le taux de stunting entre groupes.

Facteur	Groupe le plus exposé	Taux	Groupe le moins exposé	Taux	Écart
Richesse du ménage	Q1-Très pauvre	33.5%	Q5-Très riche	9.6%	23.9 pts
Âge de l'enfant	2 ans	36.0%	0 an	13.1%	22.9 pts
Accès à l'électricité	Sans électricité	30.1%	Avec électricité	14.2%	15.9 pts
Milieu de résidence	Rural	29.7%	Urbain	18.2%	11.5 pts
Source d'eau potable	Non améliorée	31.0%	Améliorée	23.1%	7.9 pts
Sexe de l'enfant	Masculin	29.0%	Féminin	24.4%	4.6 pts
Rang de naissance	4e enfant et +	28.0%	1er enfant	25.3%	2.7 pts




Figure 1: Distribution globale du stunting

Stunting selon le milieu de résidence(congo 2011-2012)




Figure 2: Distribution du stunting par milieu de résidence

Stunting selon le quintile de richesse du ménage(congo 2011-12)




Figure 3: Distribution du stunting par quintile de richesse

Stunting selon l'accès aux services essentiels(Congo 2011-12)




Figure 4: Stunting selon l'accès à l'électricité et à l'eau potable

Stunting selon le sexe et l'âge de l'enfant (Congo 2011-12)




Figure 5: Stunting selon l'âge et le sexe de l'enfant




Figure 6: Stunting par rang de naissance

2.2 Observations clés

Le niveau de richesse du ménage est le facteur le plus discriminant observé. L'écart de 23.9 points entre le quintile le plus pauvre et le plus riche dépasse celui de tous les autres facteurs pris individuellement.

L'âge suit un schéma en cloche caractéristique de la "fenêtre des 1000 jours". Le taux de stunting passe de 13.1% à la naissance à un pic de 36.0% vers 2 ans, avant de redescendre légèrement, cohérent avec la littérature scientifique sur la période critique de développement nutritionnel.

Les facteurs d'accès aux services essentiels (électricité, eau) montrent un gradient cohérent avec l'hypothèse de départ : l'accès limité aux infrastructures de base est associé à un risque accru de malnutrition chronique.

Le sexe et le rang de naissance ont un effet réel mais modeste comparé aux facteurs socio-économiques et à l'âge.

2.3 Limite méthodologique

Cette analyse est univariée : chaque facteur est examiné indépendamment des autres. Or, richesse, électricité, accès à l'eau et milieu de résidence sont vraisemblablement corrélés entre eux (un ménage rural pauvre cumule souvent plusieurs désavantages simultanément). Cette analyse ne permet donc pas d'isoler l'effet propre de chaque variable une fois les autres prises en compte.

La modélisation multivariée (section 3) permettra d'estimer l'importance relative de chaque facteur en tenant compte des autres simultanément.

3. Résultats de la modélisation

3.1 Approche méthodologique

Deux modèles de classification supervisée ont été construits et comparés afin de prédire le risque de retard de croissance (stunting) à partir de neuf variables socio-démographiques : milieu de résidence, indice de richesse du ménage, source d'eau potable, type d'assainissement, accès à l'électricité, sexe du chef de ménage, sexe de l'enfant, âge de l'enfant et rang de naissance.

Les données ont été séparées en un ensemble d'entraînement (80%, 3 580 observations) et un ensemble de test (20%, 895 observations), avec stratification selon la variable cible afin de préserver la même proportion de cas positifs dans les deux ensembles (26.7%).

Le prétraitement des données (imputation des valeurs manquantes, encodage des variables catégorielles, mise à l'échelle) a été intégré dans un pipeline scikit-learn appris exclusivement sur l'ensemble d'entraînement, conformément aux bonnes pratiques de prévention de la fuite de données entre les phases d'apprentissage et d'évaluation.

Étant donné le déséquilibre modéré de la variable cible (26.7% de cas positifs), les modèles ont été entraînés avec une pondération équilibrée des classes (`class_weight='balanced'`), et l'évaluation a privilégié des métriques adaptées à ce contexte (F1-score, rappel, aire sous la courbe ROC) plutôt que l'exactitude globale, connue pour être trompeuse sur des données déséquilibrées.

3.2 Modèles évalués

Modèle de référence — Régression logistique

Métrique	Valeur
Precision	0.328
Recall	0.649
F1-score	0.436
ROC-AUC	0.623

Modèle de comparaison — Random Forest (200 arbres, profondeur maximale de 8 niveaux)

Métrique	Valeur
Precision	0.371
Recall	0.678
F1-score	0.479
ROC-AUC	0.655

Le modèle Random Forest surpasse la régression logistique sur l'ensemble des quatre métriques d'évaluation, avec une amélioration modérée mais constante. Ce résultat est cohérent avec les observations de l'analyse exploratoire, qui avait mis en évidence une relation non linéaire entre l'âge de l'enfant et le risque de stunting — une relation que le Random Forest est structurellement mieux à même de capturer qu'un modèle linéaire.

Le Random Forest a été retenu comme modèle final, tant pour ses performances supérieures que pour l'interprétabilité qu'offre l'analyse de l'importance des variables.

3.3 Importance des variables (analyse multivariée)

L'analyse de l'importance des variables du modèle Random Forest permet d'estimer la contribution de chaque facteur à la prédiction, une fois l'ensemble des autres facteurs pris en compte simultanément — une lecture complémentaire à l'analyse univariée présentée en section 2.

Comparaison des modèle — Régression Logistique Vs Random Forest




Figure 7: Comparaison des modèles — métriques et courbes ROC

Matrice de confusion — Régression Logistique

Recall : 64.9% · Precision : 32.8% · F1 : 0.436




Figure 8: Matrice de confusion — Random Forest

Rang	Variable	Importance
1	Âge de l'enfant	23.4%
2	Richesse du ménage	13.9%
3	Source d'eau potable	13.8%
4	Rang de naissance	13.4%
5	Accès à l'électricité	11.5%
6	Assainissement	9.8%
7	Sexe de l'enfant	5.7%
8	Milieu de résidence	5.0%
9	Sexe du chef de ménage	3.7%




Figure 9: Importance des variables — analyse multivariée

L'âge de l'enfant demeure le facteur le plus déterminant dans l'analyse multivariée, confirmant l'observation faite en section 2 concernant la fenêtre critique des 1 000 premiers jours de vie.

Le rang de naissance présente un résultat notable : alors que l'analyse univariée (section 2) ne montrait qu'un écart modeste de 2.7 points de pourcentage entre le premier enfant et les enfants de rang 4 et plus, son importance relative dans le modèle multivarié (13.4%) est nettement supérieure à ce que suggérait l'analyse descriptive seule. Ce résultat illustre l'intérêt d'une approche multivariée pour révéler des effets masqués par des interactions entre variables.

Le milieu de résidence, en revanche, voit son importance relative diminuer fortement dans l'analyse multivariée (5.0%, avant-dernier rang) par rapport à son poids apparent dans l'analyse univariée (écart de 11.5 points, quatrième rang). Cette diminution suggère que l'effet du milieu de résidence observé en analyse univariée est en grande partie capté par d'autres variables corrélées, notamment la richesse du ménage et l'accès aux infrastructures de base.

3.4 Limites du modèle

Les performances du modèle final restent modestes (F1-score de 0.479, ROC-AUC de 0.655), ce qui indique que les neuf variables socio-démographiques disponibles n'expliquent qu'une partie limitée du phénomène observé. Cette limite est cohérente avec la littérature sur les déterminants de la malnutrition infantile, qui identifie généralement des facteurs additionnels non mesurés dans le présent modèle, tels que les pratiques alimentaires du nourrisson, l'état de santé maternelle, l'historique des maladies infectieuses de l'enfant, ou la diversité du régime alimentaire du ménage.

La stratégie de pondération équilibrée des classes, choisie pour privilégier la détection des cas à risque (rappel) dans une perspective de santé publique, entraîne un nombre significatif de faux positifs (precision de 0.371). Ce compromis est jugé acceptable dans un contexte de ciblage préventif, où le coût de ne pas détecter un enfant réellement à risque est considéré comme supérieur au coût d'un dépistage complémentaire inutile.

Enfin, le modèle a été entraîné et évalué exclusivement sur les données du Congo (Brazzaville) issues de l'enquête DHS 2011-12. Sa capacité de généralisation à d'autres contextes nationaux ou à des périodes plus récentes n'a pas été testée à ce stade du projet.

4. Conclusions et limites générales

4.1 Synthèse des résultats

Cette étude a analysé les facteurs socio-démographiques associés au retard de croissance (stunting) chez 4 475 enfants de moins de cinq ans au Congo (Brazzaville), à partir des microdonnées de l'Enquête Démographique et de Santé 2011-12.

Le taux global de stunting observé dans l'échantillon est de 26.7%, cohérent avec les niveaux rapportés dans la littérature sur la malnutrition chronique en Afrique centrale pour la période considérée.

L'analyse exploratoire univariée a mis en évidence des écarts significatifs selon plusieurs facteurs, le plus marqué étant le niveau de richesse du ménage (écart de 23.9 points de pourcentage entre le quintile le plus pauvre et le plus riche), suivi par l'âge de l'enfant, qui présente une évolution en cloche caractéristique de la fenêtre critique des 1 000 premiers jours de vie (pic de 36.0% vers l'âge de deux ans).

La modélisation par apprentissage supervisé, comparant une régression logistique et un modèle Random Forest, confirme l'importance prépondérante de l'âge de l'enfant dans une perspective multivariée (23.4% de l'importance du modèle retenu), et révèle un résultat notable : le rang de naissance, dont l'effet apparaissait modeste en analyse univariée, se révèle nettement plus déterminant une fois les interactions entre variables prises en compte (13.4% d'importance, quatrième facteur le plus déterminant).

4.2 Portée et limites de l'étude

Les résultats de cette étude doivent être interprétés à la lumière de plusieurs limites méthodologiques.

Nature transversale des données. L'enquête DHS 2011-12 constitue une photographie à un instant donné. Les relations observées entre facteurs socio-démographiques et stunting sont de nature associative et ne permettent pas d'établir de lien de causalité directe.

Variables disponibles limitées. Le modèle repose sur neuf variables socio-démographiques et ne permet d'expliquer qu'une partie du phénomène observé, ce qui se traduit par des performances prédictives modestes (F1-score de 0.479, aire sous la courbe ROC de 0.655). Des facteurs additionnels reconnus dans la littérature sur la malnutrition infantile — pratiques d'allaitement, diversité alimentaire du nourrisson, état de santé maternelle, historique des épisodes infectieux — n'ont pas été intégrés dans cette phase de l'analyse.

Ancienneté relative des données. L'enquête utilisée date de 2011-12. La situation nutritionnelle actuelle au Congo peut différer de celle observée à cette période, notamment en raison de l'évolution des conditions socio-économiques et des politiques publiques mises en œuvre depuis lors.

Portée géographique. L'analyse est circonscrite au Congo (Brazzaville). Aucune généralisation à d'autres contextes nationaux n'a été testée dans cette phase du projet, bien que l'accès aux données de la République

Démocratique du Congo et du Cameroun ait été obtenu en vue d’une possible extension comparative ultérieure.

4.3 Apport et perspectives

Cette étude illustre l’intérêt d’une approche combinant analyse exploratoire et modélisation prédictive pour documenter les disparités nutritionnelles infantiles à partir de données individuelles, plutôt que d’indicateurs macroéconomiques agrégés. La méthodologie développée — nettoyage structuré des microdonnées DHS, gestion rigoureuse du déséquilibre de classes, analyse multivariée de l’importance des variables — est reproductible et transposable à d’autres enquêtes DHS ou à d’autres indicateurs de malnutrition infantile (insuffisance pondérale, émaciation).

Les résultats, notamment l’importance relative de l’âge de l’enfant et du rang de naissance, pourraient utilement informer la conception de programmes de ciblage nutritionnel priorisant les enfants dans leur seconde année de vie et les familles nombreuses, en complément des critères de ciblage géographique et économique classiquement utilisés.

Citation des données :

The DHS Program, Congo Standard DHS 2011-12. ICF International, Rockville, Maryland, USA.

Auteur du rapport : MPOY Schekina Lutte-De-Vie

Institution : Université Denis Sassou Nguesso (UDSN), Kintélé, République du Congo

Contact : mpoyschekinaluttdevie@gmail.com